

Fuentes de Datos - 1

Introducción

Los problemas de minería de datos relacionan distintas disciplinas/herramientas para su abordaje (Figura 1). Dentro de éstas, las bases de datos van a ser el principal insumo para resolver el problema.




Figura 1

Aquí nos referimos como “base de datos” al conjunto de datos que tenemos disponible, independientemente del formato. Muy frecuentemente los datos disponibles van a estar en papel y para poder utilizarlos se deberá pasar a un formato digital.

Las bases de datos pueden ser una base de datos literalmente hablando (SQL o no SQL), a la que tendremos que acceder para poder obtener los registros que necesitemos; o tablas en formato de archivo (valores separados por comas, tabulaciones, de texto, Excel, etc.) que serán las fuentes de datos que se van a utilizar más frecuentemente.

Pero además de estos tipos de datos “clásicos”, muchas veces es necesario obtenerlos de otras fuentes, como puede ser de la web (un archivo o información de una página) o de otros formatos de archivo que requieren un tratamiento previo para poder utilizarlos (imágenes o archivos PDF).

Acceso clásico a datos en R

La instalación base de R tiene conjuntos de datos de prueba que pueden utilizarse, del paquete *Datasets*. Ejecutando la función `data()`, sin argumento, podemos acceder al listado completo.

Para cargar el conjunto de datos, usamos la función mencionada con el nombre:

data(nombre)

Algunos de los más utilizados son: iris, cars, mtcars, airpassengers, entre otros.

También podemos utilizar datos externos, cómo archivos de texto (TXT o CSV) o archivos de Excel, que son los más comúnmente utilizados.

Para leer archivos de texto vamos a utilizar la función `read.csv()` y para archivos de excel, la función `read_excel()` del paquete **readxl** [1].

Para el caso de archivos grandes (incluso de varios gigabytes), es recomendable utilizar la función `fread()` del paquete **data.table** [2] ya que es significativamente más rápida que `read.csv()` del paquete base de R.

Otras fuentes de datos: web

Para obtener datos de páginas web, desde R lo vamos a poder hacer de dos formas, descargando directamente el archivo o capturando la información de interés directamente de la página web.

En el primer caso, vamos a utilizar la función `download.file()` de la instalación base de R. Los argumentos que necesitamos son la URL del archivo y la ubicación y nombre del archivo de salida:

***download.file(url = “dirección del archivo”,
destfile = “path archivo de salida”)***

El segundo caso es un poco más complejo, ya que vamos a tener en cuenta el código fuente de la página en cuestión. Este código es HTML (Hyper Text Markup Language), que define el contenido y la estructura de una página web (Figura 2).




Figura 2. Página y código HTML.

Para poder recorrer el código desde el navegador y ver entre que etiquetas está el contenido que nos interesa, hacemos click con el botón derecho en la página que nos interesa y elegimos “Inspeccionar” o “Ver código fuente” en Firefox o Chrome.

Para extraer información de una página web vamos a utilizar el paquete **rvest** [3] de R. En particular las funciones `read_html()` para cargar el código de la página; `html_nodes()/html_elements()` para obtener un elemento determinado

del código de la página web; *html_table()* para obtener elementos de tipo tabla directamente y *html_text()* para obtener texto directamente.

Para *read_html()*, el único parámetro que necesitamos es la URL de la página que vamos a utilizar.

Las otras funciones van a tener como argumento el código de la página que obtenemos con *read_html()* y luego, vamos a utilizar el parámetro **css**.

CSS (Cascading Style Sheets) define la apariencia de los elementos HTML. Los selectores CSS suelen utilizarse para dar estilo a determinados subconjuntos de elementos, pero también se pueden utilizar para extraer elementos de una página web. Para encontrar el selector CSS que nos interesa, hacemos click derecho sobre el código y elegimos en “Copiar”, la opción “Selector CSS”.

Actividades

1 – Descargue el archivo TetuanCityPowerConsumption.csv desde la URL:

<https://archive.ics.uci.edu/ml/machine-learning-databases/00616/Tetuan%20City%20power%20consumption.csv>

2 – Obtenga la tabla de ganadores del Super Bowl de la NFL a partir de la página: <http://www.espn.com/nfl/superbowl/history/winners>

Guarde los datos en un archivo de valores separados por comas.

3 – Obtenga los datos de la tabla de graduados de la Universidad de Stanford, desde el año 1980 al 2007:

<https://statistics.stanford.edu/people/alumni>

Guarde el resultado en un archivo de valores separados por comas.

4 – Leer el artículo sobre ética en el rastreo web de James Densmore:

<https://medium.com/data-science/ethics-in-web-scraping-b96b18136f01>

Referencias

1. Package readxl. Disponible en:
<https://cran.r-project.org/web/packages/readxl/readxl.pdf>
2. Package data.table. Disponible en:
<https://cran.r-project.org/web/packages/data.table/data.table.pdf>
3. Package rvest. Disponible en:
<https://cran.r-project.org/web/packages/rvest/rvest.pdf>