

Minería de Datos

20/03/2026





Proceso de KDD - Definición

“el proceso no trivial de identificar patrones válidos, novedosos, potencialmente útiles y, en última instancia comprensibles a partir de los datos”


(Fayyad et al. 1996).




Proceso de KDD - Definición

- No trivial
- Válido
- Novedoso
- Potencialmente útil
- Comprensible


Proceso de KDD



Proceso de KDD



Proceso de KDD



Recopilar e integrar datos





Figura 2.2. Integración en un almacén de datos.



Resumiendo

En muchos casos tendremos que adquirir además datos externos desde bases de datos públicas (como el censo, datos demográficos o climatológicos) o desde bases de datos privadas (como los datos de compañías de pagos, bancarias, eléctricas, etc.). Esto representa un reto, ya que cada fuente de datos usa diferentes formatos de registro, diferentes grados de agregación de los datos, diferentes claves primarias, diferentes tipos de error, etc. Lo primero, por lo tanto, es integrar todos estos datos. La idea de la integración de múltiples bases de datos ha dado lugar a la tecnología de **almacenes de datos** (*data warehousing*).

Proceso de KDD





Selección, limpieza y transformación

Este paso es necesario ya que algunos datos recopilados en la etapa anterior son irrelevantes o innecesarios para la tarea de minería que se desea realizar.


- Valores que no se ajustan al comportamiento general de los datos.
- La presencia de datos faltantes o perdidos.
- Selección de variables.
- Construcción de nuevas características.
- otros?
- Lo hacemos sobre todos los datos?



Samplear

Usar una muestra (*sample*) a partir de algunos datos (o filas). La selección de la muestra debe ser hecha cuidadosamente para asegurar que es verdaderamente aleatoria y representativa.

Proceso de KDD





Introducción

La fase de minería de datos es la más característica del KDD y, por esta razón, muchas veces se utiliza esta fase para nombrar todo el proceso. El objetivo de esta fase es producir nuevo conocimiento que pueda utilizar el usuario.



Tareas de la minería de Datos

Dentro de la minería de datos hemos de distinguir tipos de tareas, cada una de las cuales puede considerarse como un tipo de problema a ser resuelto por un algoritmo de minería de datos. Esto significa que cada tarea tiene sus propios requisitos, y que el tipo de información obtenida con una tarea puede diferir mucho de la obtenida con otra.



Tareas de la minería de Datos



- Clasificación:
 - Binaria
 - Multiclase
- Regresión

- Clustering
- Reglas de asociación
- Correlación



Clasificación

La **clasificación** es quizá la tarea más utilizada. En ella, cada instancia (o registro de la base de datos) pertenece a una clase, la cual se indica mediante el valor de un atributo que llamamos la clase de la instancia. Este atributo puede tomar diferentes valores discretos, cada uno de los cuales corresponde a una clase.



Regresión

La **regresión** es también una tarea predictiva que consiste en aprender una función real que asigna a cada instancia un valor real. Ésta es la principal diferencia respecto a la clasificación; el valor a predecir es numérico. El objetivo en este caso es minimizar el error entre el valor predicho y el valor real.



Clustering

El **agrupamiento** (*clustering*) es la tarea descriptiva por excelencia y consiste en obtener grupos “naturales” a partir de los datos. Hablamos de grupos y no de clases, porque, a diferencia de la clasificación, en lugar de analizar datos etiquetados con una clase, los analiza para generar esta etiqueta. Los datos son agrupados basándose en el principio de maximizar la similitud entre los elementos de un grupo minimizando la similitud entre los distintos grupos.



Correlación

Las **correlaciones** son una tarea descriptiva que se usa para examinar el grado de similitud de los valores de dos variables numéricas. Una fórmula estándar para medir la correlación lineal es el coeficiente de correlación de Pearson.



Reglas de Asociación

Las **reglas de asociación** son también una tarea descriptiva, muy similar a las correlaciones, que tiene como objetivo identificar relaciones no explícitas entre atributos *categoricos*.


Pueden ser de muchas formas, aunque la formulación más común es del estilo “si el atributo X toma el valor A *implica que* el atributo Y toma el valor B ”.

Las reglas de asociación no implican una relación causa-efecto, es decir, puede no existir una causa para que los datos estén asociados.



Un caso especial de reglas de asociación, que recibe el nombre de **reglas de asociación secuenciales**, se usa para determinar patrones secuenciales en los datos. Estos patrones se basan en secuencias temporales de acciones y difieren de las reglas de asociación en que las relaciones entre los datos se basan en el tiempo.

Las reglas de asociación también pueden utilizarse para clasificar.




**Una vez determinada la
tarea y elegido el
modelo... ¿Qué?**



Es en la construcción del modelo donde vemos mejor el carácter iterativo del proceso de KDD, ya que será necesario explorar modelos alternativos hasta encontrar aquel que resulte más útil para resolver nuestro problema. Así, una vez obtenido un modelo y a partir de los resultados obtenidos para el mismo, **podríamos querer construir otro modelo usando la misma técnica pero otros parámetros o variables**, o quizás usar otras técnicas o herramientas.

En esta búsqueda del “buen modelo” puede que tengamos que retroceder hasta fases anteriores y hacer cambios en los datos que estamos usando o incluso modificar la definición del problema. Es más, la elección de la tarea a realizar y del algoritmo a usar puede influir en la preparación de los datos (por ejemplo, un determinado algoritmo o técnica puede requerir que los datos se presenten en un formato determinado).

Proceso de KDD





Evaluación del Modelo

Para entrenar y probar un modelo se parten los datos en dos conjuntos: el conjunto de entrenamiento (*training set*) y el conjunto de prueba o de test (*test set*). Esta separación es necesaria para garantizar que la validación de la precisión del modelo es una medida independiente . Si no se usan conjuntos diferentes de entrenamiento y prueba, la precisión del modelo será sobreestimada, es decir, tendremos estimaciones muy optimistas.

Validación Simple

Validación cruzada



Bootstrapping

Otra técnica para estimar el error de un modelo cuando se disponen de **pocos datos**.

Consiste en construir primero un modelo con todos los datos iniciales. Entonces, se crean numerosos conjuntos de datos, llamados *bootstrap samples*, haciendo un muestreo de los datos originales con reemplazo, es decir, se van seleccionando instancias del conjunto inicial, pudiendo seleccionar la misma instancia varias veces.



Evaluación del Modelo: ¿cómo lo medimos?

Dependiendo de la tarea de minería de datos existen diferentes medidas de evaluación de los modelos.

¿Cuáles conocen?

Evaluación del Modelo - Clasificación

		Predicción	
		Positivos	Negativos
Observación	Positivos	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

- **VP** es la cantidad de *positivos* que fueron *clasificados correctamente* como positivos por el modelo.
- **VN** es la cantidad de *negativos* que fueron *clasificados correctamente* como negativos por el modelo.
- **FN** es la cantidad de *positivos* que fueron *clasificados incorrectamente* como negativos.
- **FP** es la cantidad de *negativos* que fueron *clasificados incorrectamente* como positivos.



Evaluación del Modelo - Métricas

Exactitud (Accuracy)

En general, que porcentaje de la data clasifica correctamente?

$$\text{Exactitud} = \frac{VP + VN}{Total}$$

Tasa de error (Misclassification Rate)

En general, que porcentaje de la data clasifica incorrectamente?

$$\text{Tasa de error} = \frac{FP + FN}{Total}$$



Evaluación del Modelo - Métricas

Precisión

Cuando predice positivos, que porcentaje clasifica correctamente?

$$\text{Precisión} = \frac{VP}{\text{Total clasificados positivos}}$$

Valor de predicción negativo

Cuando predice negativo, que porcentaje clasifica correctamente?

$$VPN = \frac{VN}{\text{Total clasificados negativos}}$$



Evaluación del Modelo - Métricas

Sensibilidad, exhaustividad, Tasa de verdaderos positivos

Traducción al inglés,

- Recall
- Sensitivity
- True Positive Rate

Cuando la clase es positiva, que porcentaje logra clasificar?

$$\text{Sensibilidad} = \frac{VP}{\text{Total Positivos}}$$

Especificidad, tasa de verdaderos negativos

Traducción al inglés,

- Especificity
- True Negative Rate

Cuando la clase es negativa, que porcentaje logra clasificar?

$$\text{Especificidad} = \frac{VN}{\text{Total Negativos}}$$



Relación entre sensibilidad y especificidad: Curva ROC

Por las siglas de en inglés de *Receiver Operating Characteristic* (Característica operativa del receptor). La curva ROC es una representación gráfica del rendimiento del clasificador.

El área bajo la curva ROC (AUC) es la medida numérica de ese rendimiento:

$$0 \leq \text{AUC} \leq 1$$


AUC = 0.5 indica que el modelo es tan bueno como “tirar una moneda”.

AUC = 1 = modelo “perfecto” (no existe).



Relación entre sensibilidad y especificidad Curva ROC

Representa la sensibilidad vs. $(1 - \text{especificidad})$ o lo que es lo mismo: tasa de verdaderos positivos vs. tasa de falsos positivos.






Evaluación del Modelo - Regresión

$$MSE = \frac{1}{N} \sum_{x=1}^N (h(x) - f(x))^2$$

$$RMSE = \sqrt{MSE}.$$

Donde **$h(\mathbf{x})$** es el valor encontrado por el modelo y **$f(\mathbf{x})$** el valor real que tienen los datos.

Proceso de KDD





Fase de difusión, uso y Monitorización

Una vez construido y validado el modelo puede usarse principalmente con dos finalidades: para que un analista recomiende acciones basándose en el modelo y en sus resultados, o bien para aplicar el modelo a diferentes conjuntos de datos.

Tanto en el caso de una aplicación manual o automática del modelo, es necesario su difusión, es decir que se distribuya y se comunique a los posibles usuarios, ya sea por cauces habituales dentro de la organización, reuniones, intranet, etc.

También es importante medir lo bien que el modelo evoluciona.