

Minería de Datos

Clase del 27/03/2026





Calidad de los Datos





Calidad de Datos

Se ha avanzado mucho en el diseño y desarrollo de restricciones de integridad de los sistemas de información, éstos han crecido de tal manera en las últimas décadas, que el problema de calidad de datos, en vez de resolverse, en muchos casos se ha acentuado.

¿Por qué?

- Inconsistencias
- Faltantes
- Dificultades al integrar datos.



Preparación de datos o preprocesamiento

“...tiene como objetivo la eliminación del mayor número posible de datos erróneos o inconsistentes (limpieza) e irrelevantes (criba), y trata de presentar los datos de la manera más apropiada para la minería de datos.”



Tipos de datos

Numéricos: sean enteros (discretos) o reales (continuos).

Nominales/categóricos: número finito de valores (categorías). Las categorías pueden o no tener orden.

Datos de fecha y hora: tipo especial de datos numérico.

Datos de texto: texto como cadenas de caracteres.

Datos binarios: verdadero o falso.



La integración de datos y sus problemas

Al identificar objetos (Definición del ID).

Datos faltantes (el dato se registra en una fuente pero no en la otra)

Datos inconsistentes (el dato es diferente en una fuente y otra)



La integración de datos y sus problemas


Ejemplo:

- Se puede tener el DNI como cadena “42.XXX.XXX”, con y sin separador de miles.
- Como número.
- Como parte de la CUIT: 20-42XXXXXX-7, con y sin guiones.




La integración de datos: combinaciones de tablas con R


Intersección




Unión



Unión izquierda



Unión derecha





La integración de datos: combinaciones de tablas con R

	id	nombre	salario_mensual
1	1	Andrew	1424
2	2	Susan	1425
3	3	John	1156
4	4	Joe	1570
5	5	Jack	1223
6	6	Jacob	1462
7	7	Mary	1641
8	8	Kate	1603

	id	nombre	edad	puesto
1	1	Andrew	40	CTO
2	2	Susan	38	CFO
3	3	John	54	Administrativo
4	4	Joe	66	Técnico
5	6	Jacob	38	Técnico
6	7	Mary	53	Técnico
7	8	Kate	56	Técnico
8	9	Jacqueline	55	Técnico
9	10	Ivy	43	Técnico



La integración de datos: Intersección (Inner join)


Función *merge(x, y, by = c("id", "nombre"))*

	id	nombre	salario_mensual	edad	puesto
1	1	Andrew	1424	40	CTO
2	2	Susan	1425	38	CFO
3	3	John	1156	54	Administrativo
4	4	Joe	1570	66	Técnico
5	6	Jacob	1462	38	Técnico
6	7	Mary	1641	53	Técnico
7	8	Kate	1603	56	Técnico

La integración de datos: Unión (Full join)

	id	nombre	salario_mensual	edad	puesto
1	1	Andrew	1424	40	CTO
2	2	Susan	1425	38	CFO
3	3	John	1156	54	Administrativo
4	4	Joe	1570	66	Técnico
5	5	Jack	1223	NA	NA
6	6	Jacob	1462	38	Técnico
7	7	Mary	1641	53	Técnico
8	8	Kate	1603	56	Técnico
9	9	Jacqueline	NA	55	Técnico
10	10	Ivy	NA	43	Técnico

Proceso de KDD





La integración de datos: combinaciones de tablas con R

	id	nombre	salario_mensual
1	1	Andrew	1424
2	2	Susan	1425
3	3	John	1156
4	4	Joe	1570
5	5	Jack	1223
6	6	Jacob	1462
7	7	Mary	1641
8	8	Kate	1603

	id	nombre	edad	puesto
1	1	Andrew	40	CTO
2	2	Susan	38	CFO
3	3	John	54	Administrativo
4	4	Joe	66	Técnico
5	6	Jacob	38	Técnico
6	7	Mary	53	Técnico
7	8	Kate	56	Técnico
8	9	Jacqueline	55	Técnico
9	10	Ivy	43	Técnico



La integración de datos: Unión izquierda (Left join)

	id	nombre	salario_mensual	edad	puesto
1	1	Andrew	1424	40	CTO
2	2	Susan	1425	38	CFO
3	3	John	1156	54	Administrativo
4	4	Joe	1570	66	Técnico
5	5	Jack	1223	NA	NA
6	6	Jacob	1462	38	Técnico
7	7	Mary	1641	53	Técnico
8	8	Kate	1603	56	Técnico



La integración de datos: Unión derecha (Right join)

	id	nombre	salario_mensual	edad	puesto
1	1	Andrew	1424	40	CTO
2	2	Susan	1425	38	CFO
3	3	John	1156	54	Administrativo
4	4	Joe	1570	66	Técnico
5	6	Jacob	1462	38	Técnico
6	7	Mary	1641	53	Técnico
7	8	Kate	1603	56	Técnico
8	9	Jacqueline	NA	55	Técnico
9	10	Ivy	NA	43	Técnico



Reconocimiento o exploración

Una vez realizada la integración es necesario conocer las características de los diferentes datos.

Cómo se distribuyen, cuáles son los valores más frecuentes, Cuál es su dispersión. Identificar outliers, faltantes o datos ingresados con diferentes valores.

Para esto utilizaremos...

Análisis Multivariado



Algunas herramientas...

Histogramas
y/o Boxplot



Gráficos de
Dispersión



Gráficos de
Correlación

Permiten conocer características, identificar faltantes,
Valores erróneos y la posibilidad de generar nuevas
variables ya sea calculadas o dummies.



Datos faltantes



Tratamiento de datos faltantes

Tanto para la detección, como para su tratamiento posterior, es importante saber el porqué de los valores faltantes.

- Algunos valores faltantes expresan características relevantes.
- Valores no existentes. Muchos valores faltantes existen en la realidad, pero otros no.
- Datos incompletos: si los datos vienen de fuentes diferentes, al combinarlos se suele hacer la unión y no la intersección de campos, con lo que muchos datos faltantes representan que esas tuplas vienen de una/s fuente/s diferente/s al resto.



Las posibles acciones sobre datos faltantes son:

- **Ignorar:** algunos algoritmos son robustos a datos faltantes.
- **Eliminar la columna:** cuando el porcentaje de faltantes es muy alto en una variable.
- **Eliminar la fila:** claramente sesga los datos, porque muchas veces las causas de un dato faltante están relacionadas con casos o tipos especiales.
- **Reemplazar el valor:** se puede intentar reemplazar el valor manual o automáticamente. O se puede intentar predecirlo a partir de los otros ejemplos (“imputación de datos perdidos”), utilizando cualquier técnica predictiva de aprendizaje automático o técnicas más específicas según la variable (por ejemplo, de terminar el sexo a partir del nombre).



- **Segmentar:** se segmentan los registros por los valores que tienen disponibles. Obtener modelos diferentes para cada segmento y luego combinarlos.
- **Modificar la política** de calidad de datos y esperar hasta que los datos faltantes estén disponibles (no siempre es posible).

Valores erróneos



Tratamiento de datos erróneos

Los atributos erróneos son mucho más graves cuando afectan a un atributo que va a ser utilizado como clase o como valor de salida de una tarea predictiva de minería de datos.

- **Ignorar:** algunos algoritmos son robustos a datos anómalos.
- **Modificar el formato:** para casos detectables fácilmente (fechas o separador decimal).
- **Eliminar la columna:** solución extrema. Preferible a eliminar la columna es reemplazarla por una columna discreta diciendo si el valor era normal u erróneo (por encima o por debajo). En el caso de los anómalos se puede sustituir por no anómalo, anómalo superior o anómalo inferior.



- **Eliminar la fila:** puede sesgar los datos, porque muchas veces las causas de un dato erróneo están relacionadas con casos o tipos especiales.
- **Reemplazar el valor:** por el valor 'nulo' si el algoritmo lo trata bien o por máximos o mínimos, dependiendo por dónde es el anómalo, o por medias. A veces se puede predecir a partir de otros datos, utilizando cualquier técnica de ML.
- **Discretizar:** transformar un valor continuo en uno discreto (por ejemplo muy alto, alto, medio, bajo, muy bajo) hace que los anómalos caigan en 'muy alto' o 'muy bajo' sin mayores problemas.



Creación de Datos y Transformación de Características.





Creación de datos

- Discretización
- Numeralización.
- Normalización

Reducción de dimensionalidad por transformación

- Análisis de Componentes Principales,
- Análisis Factorial.

Aumento de la dimensionalidad por transformación o construcción

- Aumento de la dimensionalidad mediante núcleos (kernels).
- Creación de características.