

Minería de Datos

Clase 10/04/2026





Definición

Asociar (RAE): "Juntar una cosa con otra para concurrir a un mismo fin" o "relacionar (establecer relación entre personas o cosas)".

Asociación de ideas (RAE): "Conexión mental entre ideas, imágenes o representaciones, por su semejanza, contigüidad o contraste".

Asociación (APA, American Psychological Association): "Una conexión o relación entre dos elementos (por ejemplo, ideas, acontecimientos o sentimientos) que hace que, al experimentar el primer elemento, se active una representación del segundo. Las asociaciones son fundamentales en la teoría del aprendizaje y el conductismo.



¿Qué es Asociar?

ASOCIAR:

Establecer una relación entre dos ideas o conceptos, que tienen algo en común o entre las cuales existe un tipo de implicación intelectual o sugerida.





“Asociar” en el contexto de Minería de Datos

ASOCIAR:

Establecer una *relación entre elementos dentro de un conjunto de datos*. Es el proceso de identificar conexiones entre variables que tienden a ocurrir juntas con frecuencia.



“Asociar” en el contexto de Minería de Datos

- **Asociar elementos** implica encontrar patrones en transacciones o conjuntos de datos.
- **Asociar variables** permite descubrir relaciones implícitas entre características de los datos.
- **Asociar eventos** ayuda a prever eventos futuros en función de tendencias pasadas.



Reglas de Asociación

ANTECEDENTES

R. Agrawal; T. Imielinski; A. Swami: "Mining Association Rules Between Sets of Items in Large Databases", SIGMOD Conference 1993

[LEER ARTÍCULO](#)



Reglas de Asociación - Aplicaciones

1. Comercio y recomendación de productos
2. Salud y diagnóstico médico
3. Segmentación de clientes
4. Detección de fraude
5. Análisis de textos
6. Optimización de procesos industriales



Algunas definiciones

● **Itemset**: conjunto de elementos (ítems) que aparecen juntos dentro de una transacción en una base de datos.

$$I = \{i_1, i_2, \dots, i_k\}$$

Donde:

- I es un conjunto de elementos,
- i_j representa un ítem individual dentro de la transacción.
- Un ***k-itemset*** es un conjunto de k elementos.



Algunas definiciones

● **Transacción:** conjunto de elementos que fueron adquiridos o registrados juntos en un mismo evento.

$$T = \{i_1, i_2, \dots, i_k\}$$

Donde:

- T es una transacción individual, tiene un identificador único (ID).
- i_j representa un ítem dentro de la transacción.

Un conjunto de N transacciones la expresamos como:

$$D = \{T_1, T_2, \dots, T_N\}$$



Ejemplo: datos *basket*

TID	Items
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa

En la tabla se observan 5 transacciones, una por fila.

Los ítems son 6 en total: $I = \{Pan, Leche, Pañales, Cerveza, Huevos, Gaseosa\}$



Ejemplo: datos *single*

TID	Items
1	Pan
1	Leche
2	Pan
2	Pañales
2	Cerveza
2	Huevos
3	Leche
3	Pañales
3	Cerveza
3	Gaseosa
4	Pan
4	Leche
4	Pañales
4	Cerveza
5	Pan
5	Leche
5	Pañales
5	Gaseosa



Algunas definiciones

● Una *regla de asociación* se define como una implicación de la forma:

$$X \Rightarrow Y$$

Donde:

- X y Y son itemsets disjuntos: $X \cap Y \neq \emptyset$
- X es el antecedente y Y el consecuente.



Ejemplo:

TID	Items
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa

Algunas reglas de asociación podrían ser:

- $\{Pan, Pañales\} \rightarrow \{Cerveza\}$
- $\{Leche, Pañales\} \rightarrow \{Gaseosa\}$
- $\{Pan\} \rightarrow \{Leche\}$



Resumen

TID	Items
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa

$I = \{\text{Pan, Leche, Pañales, Cerveza, Huevos, Gaseosa}\}$

$D = \{(1, \text{Pan, Leche}), (2, \text{Pan, Pañales, Cerveza, Huevos}), (3, \text{Leche, Pañales, Cerveza, Gaseosa}), (4, \text{Pan, Leche, Pañales, Cerveza}), (5, \text{Pan, Leche, Pañales, Gaseosa})\}$

Concepto	Definición	Ejemplo
Itemset	Colección de uno o más ítems	{Pan, Pañales, Cerveza, Huevos}
k-itemset	Conjunto de k ítems	Si $k = 2$: {Pan, Leche}
Conteo de soporte o support count (σ)	Cantidad de transacciones que contienen al itemset	$\sigma(\{\text{Leche, Pan, Pañales}\}) = 2$ $\sigma(\{\text{Pan, Leche}\}) = 3$



Métricas

Concepto	Definición	Ejemplo		
Soporte (S)	Es la cantidad de transacciones que contienen la X y la Y sobre el total de transacciones.	Concepto	Definición	Ejemplo
		Soporte (S)	Es la cantidad de transacciones que contienen la X y la Y sobre el total de transacciones.	$\{Leche, Pan\} \rightarrow \{Pañales\}$ $s(\{Leche, Pan, Pañales\}) = \frac{2}{5} = 0,4$
		Confianza (c)	Cantidad de transacciones que contienen la X y la Y sobre las que contienen la X.	$\{Leche, Pan\} \rightarrow \{Pañales\}$ $c = \frac{\sigma(\{Leche, Pan, Pañales\})}{\sigma(\{Leche, Pan\})} = \frac{2}{3} = 0,67$
Confianza (c)	Cantidad de transacciones que contienen la X y la Y sobre las que contienen la X.	Concepto	Definición	Ejemplo
		Soporte (S)	Es la cantidad de transacciones que contienen la X y la Y sobre el total de transacciones.	$\{Leche, Pan\} \rightarrow \{Pañales\}$ $s(\{Leche, Pan, Pañales\}) = \frac{2}{5} = 0,4$
		Confianza (c)	Cantidad de transacciones que contienen la X y la Y sobre las que contienen la X.	$\{Leche, Pan\} \rightarrow \{Pañales\}$ $c = \frac{\sigma(\{Leche, Pan, Pañales\})}{\sigma(\{Leche, Pan\})} = \frac{2}{3} = 0,67$

TID	Items
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa



Métricas

Expresado en términos de probabilidades:

$$\textit{soporte}(X \rightarrow Y) = P(X \cap Y)$$

$$\textit{confianza}(X \rightarrow Y) = P(Y|X) = \frac{P(X \cap Y)}{P(X)}$$



Notación y Observaciones

$$X \rightarrow Y (s, c)$$

Observaciones

Del itemset $\{Cerveza, Leche, Pañales\}$ podemos extraer las siguientes reglas de asociación.

$\{Leche, Pañales\} \rightarrow \{Cerveza\} (s = 0.4, c = 0.67)$

$\{Leche, Cerveza\} \rightarrow \{Pañales\} (s = 0.4, c = 1.0)$

$\{Pañales, Cerveza\} \rightarrow \{Leche\} (s = 0.4, c = 0.67)$

$\{Cerveza\} \rightarrow \{Leche, Pañales\} (s = 0.4, c = 0.67)$

$\{Pañales\} \rightarrow \{Leche, Cerveza\} (s = 0.4, c = 0.5)$

$\{Leche\} \rightarrow \{Pañales, Cerveza\} (s = 0.4, c = 0.5)$

Todas tienen el mismo soporte pero lo que varía es la confianza.

Algoritmo apriori





Algunas cuestiones a tener en cuenta

Estudiar estas técnicas puede ser complicado porque el área de estudio de las reglas de asociación no presenta una homogeneidad en los conceptos.

Dado el gran volumen de datos de los problemas con el que trabajan los algoritmos de aprendizaje de reglas de asociación, la tarea de buscar patrones que cumplan los requisitos puede parecer muy costosa porque la cantidad de itemsets crece exponencialmente.



Cómo comenzar...

1ro - Determinar en todo el Dataset cuáles son los *itemsets frecuentes*.

2do- Descubrimiento de las *reglas* contenidas en esos itemsets.

¿Qué es un itemset frecuente?

Se entiende por *itemset frecuente* a un itemset cuyo soporte es igual o mayor a un umbral pre establecido.




Búsqueda de *itemsets* frecuentes

● basa en la búsqueda de los conjuntos de items con determinada cobertura/soporte (itemset frecuentes). Para ello, en primer lugar se construyen simplemente los conjuntos formados por sólo un ítem que superan la cobertura mínima.


Este conjunto de conjuntos se utiliza para construir el conjunto de conjuntos de dos items, y así sucesivamente hasta que se llegue a un tamaño en el cual no existan conjuntos de items con la cobertura requerida.

Propiedad anti-monótona: Un itemset no puede ser frecuente si contiene algún itemset que no lo es:

Sean X y Y dos conjuntos de ítems, si $X \subseteq Y$ entonces $s(Y) \leq s(X)$



Esquema de inclusiones de k-itemset a partir de $I=\{A,B,C,D,E\}$. Para buscar itemset frecuentes.



Suponiendo que el soporte de $\{A, B\}$ no alcanza el soporte requerido.



PASOS

Inicio:

$MinC$ = soporte mínimo

k = tamaño del itemset

C_k = conjunto de los candidatos a itemset frecuente de longitud k (inicia vacío)

L_k = conjunto de los k -itemset (inicia en $k = 1$)

L = conjunto que tendrá los itemsets frecuentes (inicia vacío)

Generar los k -itemsets y guardarlos en C_k

Mientras $C_k \neq \emptyset$

Para cada elemento de C_k

Si $s(elemento) \geq MinC$ entonces $L_k = C_k$ (“podamos” los que no lo superan)

$L = L \cup L_k$

$k = k + 1$



PASOS

Final:

- Definir una Confianza mínima aceptable (C)
- Generar todas las reglas de asociación a partir de los itemset frecuentes en L
- Calcular la confianza de estas reglas
- Sólo mantener las reglas de asociación que igualen o superen la confianza mínima admitida



Veamos...





Ejemplo para una Base de Datos de 4 transacciones

Database

TID	Items
100	A C D
200	B C E
300	A B C E
400	B E

Soporte Mínimo: 50%

Confianza Mínima: 80%

Database

TID	Items
100	A C D
200	B C E
300	A B C E
400	B E

1-Itemsets	Support
{A}	2
{B}	3
{C}	3
{E}	3

 L_1

Join

Item	Support
{A B}	1
{A C}	2
{A E}	1
{B C}	2
{B E}	3
{C E}	2

 C_2

Prune

2-Itemsets	Support
{A C}	2
{B C}	2
{B E}	3
{C E}	2

 L_2

Join

itemset
{B C E}

 C_3

Prune

3-Itemsets	Support
{B C E}	2

 L_3

Itemsets Frecuentes

$$L = \left\{ \{A\}, \{B\}, \{C\}, \{E\}, \{A C\}, \right. \\ \left. \{B C\}, \{B E\}, \{C E\}, \{B C E\} \right\}$$



Se generan todas las reglas con los itemsets de L como antecedentes y consecuentes y se calcula la confianza para cada uno.

Itemsets Frecuentes

$$L = \left\{ \{A\}, \{B\}, \{C\}, \{E\}, \{A C\}, \right. \\ \left. \{B C\}, \{B E\}, \{C E\}, \{B C E\} \right\}$$

Luego se eligen sólo los de confianza mayor a 80%

En este caso serán:

$$\{A\} \rightarrow \{C\}$$

$$\{B\} \rightarrow \{E\}$$

$$\{E\} \rightarrow \{B\}$$

$$\{C E\} \rightarrow \{B\}$$

$$\{B C\} \rightarrow \{E\}$$

Rules	Confidence
$\{A\} \rightarrow \{C\}$	100
$\{B\} \rightarrow \{C\}$	66.66666667
$\{B\} \rightarrow \{E\}$	100
$\{C\} \rightarrow \{E\}$	66.66666667
$\{B\} \rightarrow \{C E\}$	66.66666667
$\{C\} \rightarrow \{B E\}$	66.66666667
$\{E\} \rightarrow \{B C\}$	66.66666667
$\{C\} \rightarrow \{A\}$	66.66666667
$\{C\} \rightarrow \{B\}$	66.66666667
$\{E\} \rightarrow \{B\}$	100
$\{E\} \rightarrow \{C\}$	66.66666667
$\{C E\} \rightarrow \{B\}$	100
$\{B E\} \rightarrow \{C\}$	66.66666667
$\{B C\} \rightarrow \{E\}$	100



Paquete arules

El paquete de R **arules** implementa el algoritmo *Apriori* para la identificación de *itemsets* frecuentes y la creación de reglas de asociación a través de la función `apriori()`.

<https://cran.r-project.org/web/packages/arules/index.html>

<https://github.com/mhahsler/arules?tab=readme-ov-file>

