

Minería de datos

Clase 24/04/2026





Algoritmo Eclat





Algoritmo ECLAT

ANTECEDENTES

M. J. Zaki, S. Parthasarathy, M. Ogihara, and W. Li: “New Algorithms for Fast Discovery of Association Rules”, KDD-97 Proceedings 1997.

[LEER ARTÍCULO](#)



Hasta ahora...

El minado de reglas de asociación se dividía en dos partes:

- Encontrar los itemsets frecuentes para un soporte mínimo y
- Generar las reglas de asociación para una confianza determinada.

Para N items existen 2^N potenciales itemsets frecuentes.



Eclat

Se basa en un enfoque de intersección, a partir de una representación vertical de los datos: en vez de utilizar las transacciones como listas de ítems, almacena cada ítem con el conjunto de ID's de las transacciones en las que aparece.

TID	Items
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa



Item	TID-List
Pan	{T1,T2,T4,T5}
Leche	{T1,T3,T4,T5}
Pañales	{T2,T3,T4,T5}
Cerveza	{T2,T3,T4}
Huevos	{T2}
Gaseosa	{T3,T5}



Ejemplo

TID	Ítems
T1	ABC
T2	ACD
T3	BCE
T4	ABD
T5	CDE
T6	ABCD
T7	BDE
T8	ACE
T9	ABCE

La siguiente tabla contiene la información de las transacciones en formato horizontal, con 9 transacciones y 5 ítems. El soporte mínimo para considerar un *itemset* frecuente es del 33% (3 apariciones sobre 9 posibles).

TID	Ítems
T1	ABC
T2	ACD
T3	BCE
T4	ABD
T5	CDE
T6	ABCD
T7	BDE
T8	ACE
T9	ABCE



Ítem K = 1	TID-List	Soporte
A	{T1,T2,T4,T6,T8,T9}	0,66
B	{T1,T3,T4,T6,T7,T9}	0,66
C	{T1,T2,T3,T5,T6,T8,T9}	0,77
D	{T2,T4,T5,T6,T7}	0,55
E	{T3,T5,T7,T8,T9}	0,55

Calculando todas las posibles intersecciones de la columna *TID-List* de la tabla para $k=1$ se obtienen los *itemsets* de longitud $k+1$.

Ítem $k = 1$	TID-List	Soporte
A	{T1,T2,T4,T6,T8,T9}	0,66
B	{T1,T3,T4,T6,T7,T9}	0,66
C	{T1,T2,T3,T5,T6,T8,T9}	0,77
D	{T2,T4,T5,T6,T7}	0,55
E	{T3,T5,T7,T8,T9}	0,55

Ítem $k = 2$	TID-List	Soporte
AB	{T1,T4,T6,T9}	0,44
AC	{T1,T2,T6,T8,T9}	0,55
AD	{T2,T4,T6}	0,33
AE	{T8,T9}	0,22
BC	{T1,T3,T6,T9}	0,44
BD	{T4,T6,T7}	0,33
BE	{T3,T7,T9}	0,33
CD	{T2,T5,T6}	0,33
CE	{T3,T5,T8,T9}	0,44
DE	{T5,T7}	0,22



De nuevo, con las intersecciones de las *TID-List* de la tabla 2-*Itemset* se obtienen los *itemsets* para $k = 3$.

Ítem $k = 2$	TID-List	Soporte
AB	{T1,T4,T6,T9}	0,44
AC	{T1,T2,T6,T8,T9}	0,55
AD	{T2,T4,T6}	0,33
BC	{T1,T3,T6,T9}	0,44
BD	{T4,T6,T7}	0,33
BE	{T3,T7,T9}	0,33
CD	{T2,T5,T6}	0,33
CE	{T3,T5,T8,T9}	0,44

Ítem $k = 3$	TID-List	Soporte
ABC	{T1,T6,T9}	0,33
ABD	{T4,T6}	0,22
ACD	{T2,T6}	0,22
BCD	{T6}	0,11
BCE	{T3,T9}	0,22
CDE	{T5}	0,11



No se pueden obtener nuevos *itemsets* de longitud mayor a $k = 3$.



Clase de equivalencia:


“Grupo de itemsets que comparten el mismo prefijo”.

Ejemplo: Clase de equivalencia con prefijo A

AB, AC, AD y AE.

En la rama de A, prefijo AB:

ABC, ABD y ABE.





Ejemplo

Los itemsets frecuentes obtenidos son:

$$L = \{\{A\}, \{B\}, \{C\}, \{D\}, \{E\}, \{AB\}, \{AC\}, \{AD\}, \{BC\}, \{BD\}, \{BE\}, \{CD\}, \{CE\}, \{ABC\}\}$$

El algoritmo *ECLAT*, permite la identificación de *itemsets* frecuentes pero no genera reglas de asociación. A pesar de ello, una vez identificados los *itemsets* frecuentes, se puede aplicar la segunda parte del algoritmo *Apriori* para obtenerlas.



Itemset maximal

Itemset frecuente que no puede ser extendido: no forma parte de ningún superconjunto frecuente.

Del ejemplo:

$\{AD\}, \{BD\}, \{BE\}, \{CD\}, \{CE\}, \{ABC\}$



ECLAT

Ventajas sobre Apriori:

- Menos escaneos sobre la base de datos transaccional.
- Mayor eficiencia en grandes volúmenes de datos (menor cantidad de combinaciones para generar los itemsets).
- Menor uso de memoria al no almacenar grandes cantidades de candidatos innecesarios.



Algoritmo FP-Growth



Algoritmo FP-Growth

ANTECEDENTES

J. Han, J. Pei and Y. Yini: “Mining Frequent Patterns without Candidate Generation”, SIGMOD Conference 2000.

[LEER ARTÍCULO](#)



FP-Growth

Para construir un algoritmo de mejor rendimiento que el Apriori propusieron una estructura de datos alternativa, llamada FP-Tree (árbol de patrones frecuentes).

Un FP-Tree almacena información acerca de conjuntos de ítems frecuentes de forma compacta y así permite realizar consultas de manera más eficiente.

Haciendo uso de dicha estructura de almacenamiento se reduce el coste de computación del proceso de obtención de reglas de asociación, pues no es necesario generar los conjuntos de ítems candidatos a frecuentes y tampoco verificar si ellos superan a un determinado umbral.



FP-Growth

- Obtener la frecuencia de aparición de cada ítem en cada transacción.
- Ordenar los ítems por frecuencia en cada transacción.
- Se van generando los árboles FP por cada transacción.

TID	Items	Items frecuentes (ordenados)
1	Pan, Leche	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos	Pan, Pañales, Cerveza
3	Leche, Pañales, Cerveza, Gaseosa	Pañales, Leche, Cerveza
4	Pan, Leche, Pañales, Cerveza	Pan, Pañales, Leche, Cerveza
5	Pan, Leche, Pañales, Gaseosa	Pan, Pañales, Leche



Ejemplo


- Se tienen 5 transacciones y 16 ítems.
- Umbral de frecuencia 3 apariciones (soporte del 60%)

TID	Items	Items frecuentes (ordenados)
1	f,a,c,d,g,i,m,p	f,c,a,m,p
2	a,b,c,f,l,m,o	f,c,a,b,m
3	b,f,h,j,o	f,b
4	b,c,k,s,p	c,b,p
5	a,f,c,e,l,p,m,n	f,c,a,m,p



Ejemplo


TID	Items frecuentes (ordenados)
1	f,c,a,m,p
2	f,c,a,b,m
3	f,b
4	c,b,p
5	f,c,a,m,p






Ejemplo

TID	Items frecuentes (ordenados)
1	f,c,a,m,p
2	f,c,a,b,m
3	f,b
4	c,b,p
5	f,c,a,m,p



Ejemplo


TID	Items frecuentes (ordenados)
1	f,c,a,m,p
2	f,c,a,b,m
3	f,b
4	c,b,p
5	f,c,a,m,p






Ejemplo

TID	Items frecuentes (ordenados)
1	f,c,a,m,p
2	f,c,a,b,m
3	f,b
4	c,b,p
5	f,c,a,m,p



Ejemplo

Item
f
c
a
b
m
p





FP-Growth

Los itemsets frecuentes resultantes son:

$$L = \{\{f\}, \{c\}, \{a\}, \{b\}, \{m\}, \{p\}, \{f, c\}, \{f, a\}, \{c, a\}, \{c, p\}, \{f, m\}, \{c, m\}, \\ \{a, m\}, \\ \{f, c, a\}, \{f, c, m\}, \{f, a, m\}, \{c, a, m\}, \{f, c, a, m\}\}$$



FP-Growth

Ventajas sobre Apriori:



- Menos escaneos sobre la base de datos transaccional, solo necesita 2.
- Mayor velocidad en grandes volúmenes de datos (por la estructura de datos en árboles FP).
- Menor uso de memoria al no almacenar grandes cantidades de candidatos innecesarios (por la estructura de datos en árboles FP).



FP-Growth vs. ECLAT

Característica	FP-Growth	ECLAT
Estrategia	Construcción de un árbol FP para almacenar transacciones de manera compacta	Utiliza listas de transacciones (tid-lists) para representar conjuntos de ítems
Escaneos de la base de datos	Solo dos escaneos para construir el árbol FP	Requiere múltiples intersecciones de tid-lists
Generación de candidatos	No genera candidatos explícitos, usa un enfoque recursivo	Genera candidatos mediante intersección de listas de transacciones
Estructura de datos	Árbol FP (Frequent Pattern Tree)	Tid-lists (listas de transacciones)
Eficiencia en bases de datos grandes	Muy eficiente en bases de datos grandes con muchos ítems	Más eficiente en bases de datos pequeñas y densas
Uso de memoria	Puede requerir más memoria para almacenar el árbol FP	Menos consumo de memoria, pero más operaciones de intersección

FP-Growth y ECLAT vs. APRIORI





Métricas





Evaluación de las reglas

Además de la confianza y el soporte, existen otras métricas que permiten cuantificar la calidad de las reglas y la probabilidad de que reflejen relaciones reales. Algunas de las más empleadas son:

- Lift
- Coverage
- Fisher exact test



Coverage

Es el soporte de la parte izquierda de la regla (antecedente).
Se interpreta como la frecuencia con la que el antecedente aparece en el conjunto de transacciones.



Fisher Exact Test

Devuelve el *p-value* asociado a la probabilidad de observar la regla solo por azar.

Para la regla $X \rightarrow Y$:

- H_0 : X y Y son independientes.
- H_1 : hay asociación.

Si el p -valor < 0.05 , rechazamos H_0 .



Lift

El estadístico *lift* compara la frecuencia observada de una regla con la frecuencia esperada simplemente por azar (si la regla no existe realmente). El valor *lift* de una regla “*si X entonces Y*” se obtiene acorde a la siguiente ecuación:

$$Lift(X \Rightarrow Y) = \frac{c(X \Rightarrow Y)}{s(Y)}$$



Ejemplo

ID	Ítems
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa

Calculamos el lift para:
 $\{\text{leche, Pañales}\} \rightarrow \{\text{Cerveza}\}$

Cálculo

ID	Ítems
1	Pan, Leche
2	Pan, Pañales, Cerveza, Huevos
3	Leche, Pañales, Cerveza, Gaseosa
4	Pan, Leche, Pañales, Cerveza
5	Pan, Leche, Pañales, Gaseosa

$$Lift(\{leche, pañales\} \Rightarrow \{Cerveza\}) = \frac{\frac{2}{3}}{\frac{3}{5}} = \frac{0,67}{0,6} = 1,117$$



Interpretación del lift

mayor a 1	+	La probabilidad de que ocurra el consecuente dado que ocurrió el antecedente aumenta
igual a 1	x	No hay incidencia entre las probabilidades de ocurrencia. X y Y son independientes.
menor a 1	-	La probabilidad de que ocurra el consecuente dado que ocurrió el antecedente disminuye

$$Lift(X \Rightarrow Y) = \frac{P(Y|X)}{P(Y)}$$



Lift - Interpretación

$$P(A/B) = P(A) \cdot P(B) \text{ para } B \rightarrow A$$

$$\text{Lift}(B \rightarrow A) = 1 = \frac{P(A/B)}{P(A)}$$

$$1 = \frac{P(A/B)}{P(A)}$$

$$P(A) = P(A/B)$$