

Minería de datos

Clase 08/05/2026





Reglas de Asociación y su integración con la clasificación





Introducción

Aunque las reglas de asociación se utilizan generalmente para identificar relaciones entre variables, también se pueden utilizar para la clasificación. Para esto, se pueden usar las reglas de asociación para crear características nuevas y luego utilizarlas para entrenar un modelo de clasificación.



Ejemplo 1

En un conjunto de transacciones de compras de clientes, se pueden utilizar las reglas de asociación para descubrir patrones en los productos que los clientes compran juntos. A partir de estos patrones, se pueden crear características nuevas que representan la compra frecuente de ciertos productos juntos. Estas características nuevas se pueden utilizar para entrenar un modelo de clasificación, como una red neuronal o un árbol de decisión, para predecir que productos se comprarán juntos en el futuro.



Ejemplo 2

Las reglas de asociación también se pueden utilizar para la clasificación de texto. Por ejemplo, en el análisis de sentimientos de opiniones de usuarios, las reglas de asociación se utilizan para identificar patrones de palabras que están relacionadas con diferentes emociones, como la felicidad, la tristeza o la ira. A partir de estos patrones, se pueden crear características nuevas que representan la presencia de ciertas palabras en el texto. Y utilizar estas características para entrenar un modelo de clasificación para predecir la emoción asociada al texto.



Hasta ahora...

“Si se da el conjunto de condiciones A, ENTONCES es probable que también se de el conjunto de condiciones B”.

$$A \rightarrow B$$

Métricas:

$$\text{Soporte: } S(A \rightarrow B) = \frac{\text{Nº transacciones que contienen A y B}}{\text{Nº transacciones totales}}$$

$$\text{Confianza: } C(A \rightarrow B) = \frac{\text{Nº transacciones que contienen A y B}}{\text{Nº transacciones que contienen A}}$$

$$\text{Lift: } \text{Lift}(A \rightarrow B) = \frac{C(A \rightarrow B)}{S(B)}$$



¿Cómo lo relacionamos con la clasificación?

La clasificación tiene como objetivo predecir la clase o categoría de un nuevo objeto, instancia o individuo.

Entonces, se buscan reglas donde el consecuente B es la etiqueta de la clase que se quiere predecir. El antecedente A contiene los atributos o características del elemento a clasificar.

Ejemplo: {oferta,gratis,urgente} $\rightarrow$ {spam}



Reglas de Asociación de Clases (CARs)

Dado un conjunto de ítems $I=\{i_1,i_2,...,i_n\}$, un conjunto de clases $C=\{c_1,c_2,...,c_m\}$ y un conjunto de transacciones $T^C=\{T_1,T_2,...,T_n\}$ de la forma $T=\{i_1,i_2,...,i_n,c_j\}$ tal que $\forall_{1 \leq k \leq n} [i_k \in I \wedge c_j \in C]$;

Una regla de clasificación se define como:

$$X \rightarrow c$$

Donde $X \subseteq I$ e $c \in C$.





Reglas de Asociación de Clases (CARs)

Paso a paso:

1. Encontrar un conjunto de reglas R ;
2. Ordenar el conjunto R ; y
3. Definir un criterio de decisión D que utilice a R para asignar una clase c a cada transacción T_i .

Espacio de búsqueda

Ejemplo: $I=\{i_1, i_2, i_3\}$ y $C=\{c_1, c_2\}$





Reglas de Asociación de Clases (CARs)

- $$\text{Soporte}(X \rightarrow c) = \frac{\text{N}^\circ \text{ instancias que contienen } X \text{ y pertenecen a la clase } c}{\text{N}^\circ \text{ total de instancias}}$$

$$\text{Confianza}(X \rightarrow c) = \frac{\text{N}^\circ \text{ instancias que contienen } X \text{ y pertenecen a la clase } c}{\text{N}^\circ \text{ instancias que contienen } X}$$



Reglas de Asociación de Clases (CARs)

Paso a paso:

- Encontrar un conjunto de reglas R ;
- Ordenar el conjunto R ; y
- Definir un criterio de decisión D que utilice a R para asignar una clase c a cada transacción T_i .



CARs – Criterios de ordenamiento

- **CSA** (Confianza, soporte, longitud del antecedente)
- **ACS** (Longitud del antecedente, confianza, soporte)
- **WRA** (del inglés Precisión Relativa Ponderada)



CARs – Criterios de decisión

- **La mejor regla:** utiliza la primera regla del conjunto ordenado que cubra a la transacción y le asigna la clase correspondiente.
- **Las mejores K reglas:** para cada clase usa las primeras K reglas del conjunto ordenado que cubran la transacción, se promedian las medidas de calidad de las reglas de cada clase y se asigna la clase de mayor promedio.
- **Todas las reglas:** se toman para cada clase, todas las reglas y se asigna a la transacción la clase para la que se obtiene mayor promedio.



CARs – Clasificación

Independientemente del criterio de decisión, para asignar la clase a una nueva instancia, los ítems del antecedente de la regla tienen que estar presentes en la nueva transacción.

Es decir, que se evalúan todas las CARs para ver cuáles se “activan” por el criterio de coincidencia del antecedente.

Después se aplica el criterio de decisión para determinar la clase predicha.



Algoritmos

Existen distintos tipos de algoritmos de clasificación basados en CARs:

- Clasificadores de dos etapas
- Clasificadores integrados



Algoritmos

Clasificadores de dos etapas

Primero encuentran todas las CARs que cumplen los criterios de soporte y confianza establecidos, aplicando estrategias de poda; y luego se ordenan y seleccionan para cubrir el conjunto de datos de entrenamiento. Con el subconjunto de CARs elegido se genera el clasificador.



Algoritmos

Clasificadores integrados

Utilizan distintas estrategias para generar el conjunto final de CARs: como estrategias de poda y de ordenamiento en una sola etapa, etc. Estas estrategias guían el proceso de búsqueda de CARs “buenas” sin explorar todas las combinaciones posibles.



Algoritmo CBA





Algoritmo CBA

CBA (Classification based on Association), desarrollado por Liu y colaboradores en 1998.

Etapas:

1. Generación de Reglas de Asociación.
2. Construcción del clasificador.



Algoritmo CBA

Generación de Reglas de Asociación: se basa en el algoritmo Apriori para encontrar todas las reglas que cumplen los umbrales de soporte y confianza.

Construcción del Clasificador: El clasificador se construye ordenando las reglas con el criterio CSA y utiliza el criterio de “la mejor regla” para asignar la clase a una nueva transacción.



Ejemplo

Se tienen 5 transacciones, 5 ítems y 2 clases.

Soporte mínimo de 40% (2 transacciones) y confianza mínima de 60%.

TID	Ítems	Clase
1	ABC	C1
2	AD	C1
3	BCE	C2
4	ABD	C1
5	BE	C2



Ejemplo

Para itemsets de 1 elemento: {A}, {B}, {C}, {D} y {E} son frecuentes.

{A} -> C1:

- $\text{Soporte}(A, C1) = 3/5 = 0,6$
- $\text{Confianza}(A, C1) = \text{Soporte}(A, C1) / \text{Soporte}(A) = 0,6/0,6 = 1$

{B} -> C1:

- $\text{Soporte}(B, C1) = 2/5 = 0,4$
- $\text{Confianza}(B, C1) = \text{Soporte}(B, C1) / \text{Soporte}(B) = 0,4/0,8 = 0,5$. Se poda.

TID	Items	Clase
1	ABC	C1
2	AD	C1
3	BCE	C2
4	ABD	C1
5	BE	C2



Ejemplo

Para itemsets de 1 elemento: {A}, {B}, {C}, {D} y {E} son frecuentes.

{A} -> C2:

- $\text{Soporte}(A, C2) = 0/5 = 0$

- Se poda.

{B} -> C2:

- $\text{Soporte}(B, C2) = 2/5 = 0,4$

- $\text{Confianza}(B, C2) = \text{Soporte}(B, C2) / \text{Soporte}(B) = 0,4 / 0,8 = 0,5$, se poda.

TID	Items	Clase
1	ABC	C1
2	AD	C1
3	BCE	C2
4	ABD	C1
5	BE	C2



Ejemplo

Para 2 elementos: {AB}, {AD}, {BC} y {BE} son frecuentes.

{AB} -> C1:

- $\text{Soporte}(\text{AB}, \text{C1}) = 2/5 = 0,4$
- $\text{Confianza}(\text{AB}, \text{C1}) = \text{Soporte}(\text{AB}, \text{C1}) / \text{Soporte}(\text{AB}) = 0,4/0,4 = 1$

{AB} -> C2:

- $\text{Soporte}(\text{AB}, \text{C2}) = 0/5 = 0$
- Se poda

TID	Items	Clase
1	ABC	C1
2	AD	C1
3	BCE	C2
4	ABD	C1
5	BE	C2



Ejemplo

Para 2 elementos: {AB}, {AD}, {BC} y {BE} son frecuentes.

{AD} -> C1:

- $\text{Soporte}(\text{AD}, \text{C1}) = 2/5 = 0,4$
- $\text{Confianza}(\text{AD}, \text{C1}) = \text{Soporte}(\text{AD}, \text{C1}) / \text{Soporte}(\text{AD}) = 0,4/0,4 = 1$

{BE} -> C2:

- $\text{Soporte}(\text{BE}, \text{C2}) = 2/5 = 0,4$
- $\text{Confianza}(\text{BE}, \text{C2}) = \text{Soporte}(\text{BE}, \text{C2}) / \text{Soporte}(\text{BE}) = 0,4/0,4 = 1$

TID	Items	Clase
1	ABC	C1
2	AD	C1
3	BCE	C2
4	ABD	C1
5	BE	C2



Ejemplo

Paso 2 ordenar las CARs resultantes:

- AB -> C1 (C=1,S=0.4,A=2)
- AD -> C1 (C=1,S=0.4,A=2)
- BE -> C2 (C=1,S=0.4,A=2)
- A -> C1 (C=1,S=0.6,A=1)
- D -> C1 (C=1,S=0.4,A=1)
- E -> C2 (C=1,S=0.4,A=1)
- {} -> C1 (regla default)

TID	Items	Clase
1	ABC	C1
2	AD	C1
3	BCE	C2
4	ABD	C1
5	BE	C2



Ejemplo

Clasificación de nueva transacción: {BCE}

1. Aplicar AB -> C1: Contiene AB? No aplica.
2. Aplicar AD -> C1: Contiene AD? No aplica.
3. Aplicar BE -> C2: Contiene BE? Si, entonces se asigna C2.

Clasificación de nueva transacción: {AC}

4. AB y AD no aplican.
5. Aplicar A -> C1: Contiene A? Si, entonces se asigna C1.

Algoritmo CMAR



Algoritmo CMAR

CMAR (Classification based on Multiple Association Rules), desarrollado por Li y colaboradores en 2001.

Etapas:

1. Generación de Reglas de Asociación (FP-Growth).
2. Construcción del clasificador.



Algoritmo CMAR

Generación de Reglas de Asociación: se basa en el algoritmo FP-Growth para encontrar los itemsets frecuentes y luego todas las reglas que cumplen los umbrales de soporte y confianza en una estructura CR-Tree. Utiliza el test χ^2 (Chi cuadrado) para podar las reglas.

Construcción del Clasificador: El clasificador se construye ordenando las reglas con el criterio CSA y utiliza el criterio de “todas las reglas” para asignar la clase a una nueva transacción.



Algoritmo CMAR

La asignación de la clase a una nueva transacción no se hace aplicando la regla por confianza. Al utilizar el criterio “todas las reglas”, se aplican conjuntos de reglas para cada clase y se utiliza nuevamente el χ^2 para asignar la clase de la regla mas fuerte.



CBA vs CMAR

Característica	CBA	CMAR
Enfoque Principal	Genera todas las reglas de asociación con la clase como consecuente y luego selecciona un subconjunto para clasificar.	Genera y almacena reglas de clasificación de manera eficiente utilizando un CR-tree y clasifica usando múltiples reglas.
Generación de Reglas	Basado en Apriori, con la clase en el consecuente.	Utiliza una estructura CR-tree (basada en FP-Growth).
Clasificación	Generalmente se basa en la aplicación de la "mejor" regla coincidente (según criterios de ordenamiento CSA).	Utiliza "todas" las reglas de clasificación que coinciden con la instancia y combina sus predicciones (usando análisis de chi-cuadrado ponderado).
Eficiencia	La generación de todas las reglas puede ser costosa en conjuntos de datos grandes con muchos ítems frecuentes. La selección posterior también añade complejidad.	El uso del CR-tree optimiza la generación y el almacenamiento de reglas, lo que puede hacerlo más eficiente para conjuntos de datos grandes.



CBA vs CMAR

Característica	CBA	CMAR
Precisión	La precisión puede depender en gran medida de la calidad de la "mejor" regla seleccionada.	Al considerar múltiples reglas y sus correlaciones, a menudo logra una mayor precisión en la clasificación.
Robustez	Puede ser sensible a la presencia de reglas individuales con alta confianza pero baja cobertura o viceversa.	Al utilizar múltiples perspectivas (múltiples reglas), puede ser más robusto frente a ruido o reglas engañosas.
Manejo de Datos Grandes	Puede enfrentar desafíos de escalabilidad debido a la generación potencialmente masiva de reglas.	El diseño del CR-tree está pensado para ser más eficiente en el manejo de grandes conjuntos de datos.