

Minería de datos

Clase 15/05/2026





Algoritmo CMAR

Generación de Reglas de Asociación: se basa en el algoritmo FP-Growth para encontrar los itemsets frecuentes y luego todas las reglas que cumplen los umbrales de soporte y confianza en una estructura CR-Tree. Utiliza el test χ^2 (Chi cuadrado) para podar las reglas.

Construcción del Clasificador: El clasificador se construye ordenando las reglas con el criterio CSA y utiliza el criterio de “todas las reglas” para asignar la clase a una nueva transacción.



Test de χ^2

El test de chi-cuadrado, es un test estadístico que se utiliza para evaluar la fuerza de la asociación entre el término antecedente con el término consecuente de una regla de asociación de clases.

- H_0 : el antecedente y la clase son independientes.
- H_1 : existe dependencia entre el antecedente y la clase.



Test de χ^2

Para la regla $A \rightarrow c$, la tabla de contingencia sería:

	c presente	c ausente	Total
A presente	O_{11}	O_{12}	R_1
A ausente	O_{21}	O_{22}	R_2
Total	C_1	C_2	N

Donde:

- O_{11} : Número de transacciones donde A y C están presentes.
- O_{12} : Número de transacciones donde A está presente y C está ausente.
- O_{21} : Número de transacciones donde A está ausente y C está presente.
- O_{22} : Número de transacciones donde A y C están ausentes.
- R_1, R_2 : Totales de las filas.
- C_1, C_2 : Totales de las columnas.
- N : Número total de transacciones.



Test de χ^2

El estadístico χ^2 se calcula de la siguiente forma:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Donde:

- O_{ij} : frecuencias observadas.
- E_{ij} : frecuencias esperadas.



Test de χ^2

Suponiendo H_0 verdadera (A y c son independientes) los valores esperados se calculan de esta forma:

$$E_{ij} = \frac{(Total\ Fila\ i) \times (Total\ Columna\ j)}{N}$$

Entonces:

- $E_{11} = \frac{R_1 \times C_1}{N}$
- $E_{12} = \frac{R_1 \times C_2}{N}$
- $E_{21} = \frac{R_2 \times C_1}{N}$
- $E_{22} = \frac{R_2 \times C_2}{N}$

	c presente	c ausente	Total
A presente	O_{11}	O_{12}	R_1
A ausente	O_{21}	O_{22}	R_2
Total	C_1	C_2	N



Test de χ^2

Un valor del estadístico χ^2 alto significa una mayor diferencia entre las frecuencias observadas y esperadas, lo que sugiere que hay una asociación más fuerte entre el antecedente y la clase.

Aunque el valor de χ^2 por si solo es difícil de interpretar sin observar el p-valor:

- Si el p-valor $\leq 0,05$, rechazamos H_0 . Hay evidencia estadística significativa de que existe una asociación entre el antecedente y la clase.
- Si el p-valor > 0.05 , no se rechaza H_0 . El antecedente y la clase podrían ser independientes.



Reglas de Asociación Secuenciales





Aparece el tiempo...

TID	Ítems
1	ABC
2	AD
3	BCE
4	ABD
5	BE

tiempo



ID Cliente	ID Tiempo	Ítems
1	t11	ABC
1	t21	AD
2	t12	BCE
3	t13	ABD
3	t23	BE
3	t33	CAEF



Secuencias

De la tabla con ID Cliente e ID Tiempo se pueden obtener las secuencias:

ID Cliente	ID Tiempo	Ítems
1	t11	ABC
1	t21	AD
2	t12	BCE
3	t13	ABD
3	t23	BE
3	t33	CAEF

ID Cliente	Secuencia
1	{{ABC}{AD}}
2	{{BCE}}
3	{{ABD}{BE}{CAEF}}



Análisis de secuencias

Objetivo del análisis de secuencias: descubrir patrones a partir de datos de secuencias.

Ejemplo:

Hay 3 categorías {A, B, C}, el patrón “siempre que ocurre B, a continuación ocurre A” en una secuencia:

C C C B A A B A C B A C A C B A A A A B A C C B A C B

“Siempre que el bebé llora (B), la madre lo alza (A)”



Análisis de secuencias

En general, los patrones son probabilísticos: “cuando ocurre *B*, existe una probabilidad (o tendencia) que a continuación ocurra *A*”.

A B A C B A A C C A B C B A C C C A A B A C A B A C C

Puede existir más de un patrón en la secuencia.

Los patrones se encuentran a partir de la secuencia, no al revés.



Tipo de Secuencias

Secuencias determinísticas: cuando conocemos que después que ha ocurrido A, siempre ocurre B en el instante siguiente.

Formalmente: habiendo ocurrido la categoría antecedente, podemos predecir que la consecuente ocurrirá a continuación con probabilidad 1.



Secuencias determinísticas

Ejemplo, fabricación de celulares:

- A. Colocación de placa madre en carcasa.
- B. Conexión de la batería.
- C. Colocación de pantalla
- D. Conexión de la cámara
- E. Cierre de la carcasa.
- F. Prueba del celular.

Secuencia:

A B C D E F A B C D E F A B C D E F A B C D E F



Tipo de Secuencias

Secuencias probabilísticas: cuando después que ha ocurrido A, existe una probabilidad (menor que 1) de que ocurra B en el instante siguiente.

Formalmente: habiendo ocurrido la categoría antecedente, no podemos predecir con exactitud que categoría ocurrirá a continuación.



Secuencias probabilísticas

Secuencias aleatorias: o independientes, cuando la probabilidad de que ocurra una categoría en un instante es siempre la misma, independientemente de la categoría que ocurrió antes.

Secuencias con orden: la probabilidad de que ocurra una categoría en un instante varía de acuerdo a la categoría del antecedente.



Ejemplos...

Llamadas a un call center de atención al cliente: la recepción de llamadas se modela como un proceso aleatorio, donde la probabilidad de que llegue una llamada en un instante de tiempo es independiente de cuando llegó la última llamada.

Control de inventario: la demanda de un producto no es perfectamente predecible, pero puede seguir patrones (estacionales o tendencias).



Secuencias probabilísticas

Las **secuencias aleatorias** no tienen patrones o regularidades. No existe una asociación secuencial entre los elementos o categorías.

En las **secuencias con orden**, la ocurrencia de una o varias categorías afecta la probabilidad de ocurrencia de categorías posteriores. Las secuencias con orden, contienen patrones.



Reglas de Asociación Secuenciales

Dado una base de datos de transacciones D y un conjunto de m ítems diferentes $I = \{i_1, i_2, \dots, i_m\}$, donde cada transacción $T = \{ID\text{-}Cliente, ID\text{-}Tiempo, s_i\}$. Definimos una secuencia $S = \{s_1, s_2, \dots, s_n\}$ como una lista ordenada de itemsets s_i . Una regla de asociación secuencial se define como:

$$S_1 \rightarrow S_2$$

Donde las S_j son secuencias y en la base de datos de transacciones, ningún “cliente” tiene más de una transacción con el mismo ID-Tiempo.



Reglas de Asociación Secuenciales

Todos los ítems de un mismo itemset tienen el mismo ID de tiempo.

Para cada “cliente”, sus transacciones se pueden ubicar juntas en una secuencia: la secuencia del cliente. Donde cada transacción se presenta como un itemset en la secuencia y estas se ordenan según su ID de tiempo.



Medidas



$$\text{Soporte}(S_1 \rightarrow S_2) = \frac{N^\circ \text{ secuencias que contienen } S_1 \text{ y } S_2}{N^\circ \text{ total de secuencias}}$$

$$\text{Confianza}(S_1 \rightarrow S_2) = \frac{N^\circ \text{ secuencias que contienen } S_1 \text{ y } S_2}{N^\circ \text{ secuencias que contienen } S_1}$$

$$\text{Lift}(S_1 \rightarrow S_2) = \frac{\text{Confianza}(S_1 \rightarrow S_2)}{\text{Soporte}(S_2)}$$



Secuencias

De la tabla con ID Cliente e ID Tiempo se pueden obtener las secuencias:

ID Cliente	ID Tiempo	Ítems
1	t11	ABC
1	t21	AD
2	t12	BCE
3	t13	ABD
3	t23	BE
3	t33	CAEF

ID Cliente	Secuencia
1	{{ABC}{AD}}
2	{{BCE}}
3	{{ABD}{BE}{CAEF}}



Secuencias

A partir de las secuencias, se pueden generar sub-secuencias:

Secuencia	Sub-secuencia
{{ABC}{AD}}	{{A}{AD}}
{{ABC}{AD}}	{{AB}}
{{BCE}}	{{BC}}
{{ABD}{BE}{CAEF}}	{{B}{CA}}
{{ABD}{BE}{CAEF}}	{{AB}{E}{F}}
{{ABD}{BE}{CAEF}}	{{BD}{EF}}



Reglas de Asociación Secuenciales

Pasos:

- Encontrar un conjunto secuencias frecuentes;
- Generación y evaluación de reglas de asociación secuenciales.



Algoritmos

- **AprioriALL:** se basa en Apriori.
- **SPADE**
- GSP, PrefixSpan y otros.

Algoritmo AprioriALL



Algoritmo AprioriALL

Desarrollado por Agrawal y colaboradores en 1995. Etapas:

1. Ordenado
2. Selección de itemsets
3. Transformación
4. Secuencias
5. Selección



Algoritmo AprioriALL

Ordenado: la base de datos transaccional se ordena por ID de cliente como criterio principal y por ID de tiempo (tiempo de transacción o evento) como criterio secundario. Se obtienen las secuencias por cliente.

ID Cliente	ID Tiempo	Ítems
1	23/10/2022	C
1	28/10/2022	H
2	16/10/2022	AB
2	20/10/2022	C
2	25/10/2022	DFG
3	15/10/2022	CEG
4	8/10/2022	C
4	16/10/2022	DG
4	25/10/2022	H
5	20/10/2022	H



Algoritmo AprioriALL - Ordenado

ID Cliente	ID Tiempo	Ítems
1	23/10/2022	C
1	28/10/2022	H
2	16/10/2022	AB
2	20/10/2022	C
2	25/10/2022	DFG
3	15/10/2022	CEG
4	8/10/2022	C
4	16/10/2022	DG
4	25/10/2022	H
5	20/10/2022	H

ID Cliente	Secuencia
1	{{C}{H}}
2	{{AB}{C}{DFG}}
3	{{CEG}}
4	{{C}{DG}{H}}
5	{{H}}



Algoritmo AprioriALL

Itemsets: se obtienen los itemsets frecuentes que cumplen con el umbral de soporte (Ej. : 40%, 2 apariciones). Y se mapea con un identificador entero.

ID	Itemset
1	{C}
2	{D}
3	{G}
4	{H}
5	{DG}



Algoritmo AprioriALL

Transformación: las secuencias de los clientes se reemplazan por los itemsets frecuentes que contienen y se mapean con el identificador.

ID	Itemset
1	{C}
2	{D}
3	{G}
4	{H}
5	{DG}

ID Cliente	Secuencia	Transformación	Mapeo
1	{{C}{H}}	{{C}{H}}	{{1}{4}}
2	{{AB}{C}{DFG}}	{ {C} {D}{G}{DG} }	{{1}{2,3,5}}
3	{{CEG}}	{ {C}{G} }	{{1,3}}
4	{{C}{DG}{H}}	{ {C} {D}{G}{DG} {H} }	{{1}{2,3,5}{4}}
5	{{H}}	{{H}}	{{4}}



Algoritmo AprioriALL

Secuencias: se obtienen las secuencias frecuentes, a partir de las secuencias mapeadas, que superen el soporte mínimo.

ID Cliente	Mapeo
1	{{1}{4}}
2	{{1}{2,3,5}}
3	{{1,3}}
4	{{1}{2,3,5}{4}}
5	{{4}}

Tamaño 1		Tamaño 2		Tamaño 3		Tamaño 4	
Sec.	Sop.	Sec.	Sop.	Sec.	Sop.	Sec.	Sop.
{1}	4	{1,2}	2	{1,2,3}	2	{1,2,3,5}	2
{2}	2	{1,3}	3	{1,2,5}	2		
{3}	3	{1,4}	2	{1,3,5}	2		
{4}	3	{1,5}	2	{2,3,5}	2		
{5}	2	{2,3}	2				
		{2,5}	2				
		{3,5}	2				



Algoritmo AprioriALL

Selección: se podan los patrones secuenciales que están contenidos en otro patrón secuencial de mayor tamaño. Se mantienen solamente los patrones secuenciales máximos.

Secuencia	Secuencia original	Soporte
{1,2,3,5}	{{C}{D}{G}{DG}}	2
{1,4}	{{C}{H}}	2



Algoritmo AprioriALL

Generación de reglas: para cada secuencia frecuente S , se exploran todas las posibilidades $S_1 \rightarrow S_2$, donde S_1 y S_2 son subsecuencias de S .

Para cada regla $S_1 \rightarrow S_2$ generada, se calcula la confianza de la forma:

$$Confianza(S_1 \rightarrow S_2) = \frac{Soporte(S)}{Soporte(S_1)}$$

Si la confianza de la regla es mayor que el umbral, $S_1 \rightarrow S_2$ se considera una regla fuerte.



Algoritmo SPADE



Algoritmo SPADE

El algoritmo SPADE (por las siglas en inglés de Descubrimiento secuencial de patrones mediante clases de equivalencia). Fue desarrollado por Mohammed Zaki en 2001.

[LEER ARTÍCULO](#)



Algoritmo SPADE

El algoritmo se diferencia de AprioriALL en que divide el problema en “subproblemas” optimizando el manejo de memoria ya que disminuye los recorridos por la base de datos y la generación de candidatos.

La base de datos secuencial se transforma en un formato vertical, ID-List, donde cada ID se asocia a un ítem e instante de tiempo. Almacenando una lista de la forma: ítem -> (ID-secuencia, ID-tiempo).



Algoritmo SPADE

Paso a paso:

- Encontrar los 1-temsets frecuentes: escaneo inicial de la BBDD, cálculo del soporte para cada ítem, filtrado por soporte y creación de ID-list.
- Generación de 2-secuencias frecuentes: uniendo los 1-itemsets frecuentes por evento (mismo evento) y por secuencia (eventos consecutivos). Se filtran por soporte.
- Expansión a k-secuencias frecuentes.



Algoritmo SPADE

Transformación de los datos en formato vertical ID-List.

Soporte mínimo de 40%.

ID Cliente	ID Tiempo	Ítems
1	23/10/2022	C
1	28/10/2022	H
2	16/10/2022	AB
2	20/10/2022	C
2	25/10/2022	DFG
3	15/10/2022	CEG
4	8/10/2022	C
4	16/10/2022	DG
4	25/10/2022	H
5	20/10/2022	H

{C}		{D}		{G}		{H}	
SID	TID	SID	TID	SID	TID	SID	TID
1	23	2	25	2	25	1	28
2	20	4	16	3	15	4	25
3	15			4	16	5	20
4	8						



Algoritmo SPADE

Creación de la ID-List

{C}		{D}		{G}		{H}	
SID	TID	SID	TID	SID	TID	SID	TID
1	23	2	25	2	25	1	28
2	20	4	16	3	15	4	25
3	15			4	16	5	20
4	8						

Ítem	(SID, TID)
C	(1,23)(2,20)(3,15)(4,8)
D	(2,25)(4,16)
G	(2,25)(3,15)(4,16)
H	(1,28)(4,25)(5,20)



Algoritmo SPADE

Ítem	(SID, TID)
C	(1,23)(2,20)(3,15)(4,8)
D	(2,25)(4,16)
G	(2,25)(3,15)(4,16)
H	(1,28)(4,25)(5,20)

Generación de 2-secuencias

- Por ítems dentro del mismo evento {X,Y}

Secuencia {D,G}

- D y G se encuentran en el TID 25 de la SID 2 (cliente 2).
- D y G se encuentran en el TID 16 de la SID 4 (cliente 4).
- $\text{Soporte}(\{D,G\}) = 2$



Algoritmo SPADE

Ítem	(SID, TID)
C	(1,23)(2,20)(3,15)(4,8)
D	(2,25)(4,16)
G	(2,25)(3,15)(4,16)
H	(1,28)(4,25)(5,20)

Generación de 2-secuencias

- Por ítems en eventos consecutivos $\{X\}\{Y\}$

Secuencia $\{C\}\{D\}$:

- C se encuentra en el TID 20 de la SID 2 y D en el TID 25 de la SID 2 (cliente 2).
- C se encuentra en el TID 8 de la SID 4 y D en el TID 16 de la SID 4 (cliente 4).

$\text{Soporte}(\{C\}\{D\}) = 2.$



Algoritmo SPADE

Ítem	(SID, TID)
C	(1,23)(2,20)(3,15)(4,8)
D	(2,25)(4,16)
G	(2,25)(3,15)(4,16)
H	(1,28)(4,25)(5,20)

Generación de 2-secuencias

- Por ítems en eventos consecutivos $\{X\}\{Y\}$

Secuencia $\{C\}\{G\}$:

- C se encuentra en el TID 20 de la SID 2 y G en el TID 25 de la SID 2 (cliente 2).
- C se encuentra en el TID 8 de la SID 4 y G en el TID 16 de la SID 4 (cliente 4).

$\text{Soporte}(\{C\}\{G\}) = 2$.



Algoritmo SPADE

Ítem	(SID, TID)
C	(1,23)(2,20)(3,15)(4,8)
D	(2,25)(4,16)
G	(2,25)(3,15)(4,16)
H	(1,28)(4,25)(5,20)

Generación de 2-secuencias

- Por ítems en eventos consecutivos $\{X\}\{Y\}$

Secuencia $\{C\}\{H\}$:

- C se encuentran en el TID 23 de la SID 1 y H en el TID 28 de la SID 1 (cliente 1).
- C se encuentran en el TID 8 de la SID 4 y H en el TID 25 de la SID 4 (cliente 4).

$\text{Soporte}(\{C,H\}) = 2$



Algoritmo SPADE

2-secuencias frecuentes:

$\langle \{D, G\} \rangle, \langle \{C\}\{D\} \rangle, \langle \{C\}\{G\} \rangle, \langle \{C\}\{H\} \rangle$



Algoritmo SPADE

Ítem	(SID, TID)
C	(1,23)(2,20)(3,15)(4,8)
D	(2,25)(4,16)
G	(2,25)(3,15)(4,16)
H	(1,28)(4,25)(5,20)

Generación de 3-secuencias frecuentes: combinando las 2-secuencias frecuentes (unión por ítems en un mismo evento o en eventos consecutivos).

Secuencia $\{C\}\{D,G\}$: de combinar $\{C\}\{D\}$ y $\{D,G\}$ o $\{C\}\{G\}$ y $\{D,G\}$

- C en TID 20 y $\{D,G\}$ en TID 25 en SID 2 (cliente 2).
- C en TID 8 y $\{D,G\}$ en TID 16 en SID 4 (cliente 4).

$\text{Soporte}(\{C\}\{D,G\}) = 2$.

3-secuencias frecuentes: $\langle\{C\}\{D,G\}\rangle$



Algoritmo SPADE

Secuencias frecuentes:

- 1-secuencias frecuentes: $\langle \{C\} \rangle, \langle \{D\} \rangle, \langle \{G\} \rangle, \langle \{H\} \rangle$
- 2-secuencias frecuentes: $\langle \{D, G\} \rangle, \langle \{C\}\{D\} \rangle, \langle \{C\}\{G\} \rangle, \langle \{C\}\{H\} \rangle$
- 3-secuencias frecuentes: $\langle \{C\}\{D, G\} \rangle$



Algoritmo SPADE

Reglas de Asociación Secuenciales

- 2-secuencias frecuentes: para $\{D, G\}$

$D \rightarrow G$

- Soporte($\{D, G\}$) = 2 y soporte($\{D\}$) = 2,

- confianza($D \rightarrow G$) = Soporte($\{D, G\}$) / soporte($\{D\}$) = 1 (100%)

Si un cliente compra D, el 100% de las veces también compra G, luego, en la misma transacción.