

Trabajo Integrador Final

Introducción

El objetivo del trabajo integrador es aplicar los conocimientos teóricos vistos en la materia, principalmente la exploración y preparación de datos, para la aplicación de reglas de asociación y detección de secuencias.

Entregables

Parte I – Resolución del trabajo práctico:

En equipos **de hasta dos (2) integrantes** se debe entregar un script *.R con el código utilizado para resolver el trabajo (correctamente comentado) y un informe en formato PDF con las respuestas a las actividades planteadas.

Fecha límite de entrega: miércoles 10/06 a las 17:30 hs.

Parte II - Defensa del trabajo realizado:

Las lecturas y comentarios se realizarán por medio del Aula Virtual entre el 17 de junio de 2026 y se coordinará un día y horario para la defensa del trabajo. La defensa del mismo será por grupo entre el 24 y el 26 de junio de 2026.

La defensa será de los resultados obtenidos, las dificultades presentadas y diferentes propuestas que pudieran realizar para mejorar y/o modificar los resultados. Además, se podrán hacer preguntas referidas a los contenidos teóricos de la materia aplicados en el trabajo y sobre las características del script presentado.

Contexto del problema

El comercio electrónico se ha convertido en un nuevo canal para apoyar el desarrollo de las empresas. A través de éste, las empresas pueden acceder y establecer una mayor presencia en el mercado, proporcionando canales de distribución más baratos y eficientes para sus productos y/o servicios.

El comercio electrónico también ha cambiado la forma en que la gente compra y consume productos y servicios. Muchas personas recurren a sus ordenadores o dispositivos inteligentes para pedir productos, que pueden ser entregados fácilmente en sus hogares.

En este caso, una e-shop polaca de ropa para embarazadas quiere dirigirse a los clientes con sugerencias sobre el conjunto de artículos que es más probable que un cliente compre, lo que permitirá aumentar el compromiso de los clientes, mejorar su experiencia e identificar su comportamiento.

Datos

Se trata de un conjunto de datos que contiene el flujo de clics durante distintas sesiones, en una tienda en línea con sede en Polonia, durante 5 meses del año

2008. Los datos de navegación provienen de clientes procedentes de distintos países.

El conjunto de datos contiene más de 165.000 registros y 14 variables, entre el 01/04/2008 y el 13/08/2008. Las variables disponibles son:

- Year (fecha): año del evento.
- Month (fecha): mes del evento.
- Day (fecha): día de la sesión.
- Order (numérica): secuencia de clicks durante la sesión.
- Country (categórico): nombre del país donde reside el cliente.
- Session ID (categórica): ID de la sesión.
- "page 1 (main category)" (categórica): categoría principal del producto.
- "page 2 (clothing model)" (categórica): código de cada producto.
- Colour (categórica): color del producto.
- Location (categórica): ubicación de la foto en la página, la pantalla se ha dividido en seis partes.
- Model photography (categórica): variable binaria.
- Price (numérica): el precio de cada producto por unidad en dólares estadounidenses (USD).
- Price 2 (categórica): Variable que informa de si el precio de un producto concreto es superior al precio medio de toda la categoría de productos.
- Page (categórica): número de página dentro del sitio web de la tienda electrónica.

Enlace de descarga del dataset:

<https://archive.ics.uci.edu/dataset/553/clickstream+data+for+online+shopping>

Nota: Junto a los datos propiamente dichos, hay un archivo *.txt que contiene la información de las variables y sus categorías.

Actividades

- a) Explore los datos y presente sus características principales.
- b) Utilizando las gráficas que considere adecuadas, muestre:
 - Clicks por sesión,
 - sesiones por país,
 - productos vistos por sesión; y
 - categoría de producto por sesión.
- c) ¿Cómo ha sido la evolución de los clicks de navegación a lo largo de los meses estudiados?
- d) Encuentre el número de transacciones e ítems (pensando cada sesión como una transacción).
- e) Encuentre un conjunto de itemsets frecuentes para un soporte mínimo de 2% y con una longitud mínima de 2 ítems.
- f) Encuentre las reglas de asociación para los datos de navegación correspondientes a Polonia, en la categoría "blusas". Para un soporte mínimo de 2% y una confianza de 20%. Muestre las 10 reglas de mayor soporte.
- g) Encuentre las reglas para la República Checa, en la misma categoría del ítem anterior, pero para un soporte mínimo de 4% y una confianza de 25%. Muestre las 10 reglas de mayor soporte.
- h) Compare los resultados de los dos países. ¿Qué conclusión sobre los consumidores puede obtener de los dos resultados?
- i) Encuentre las secuencias más frecuentes que tienen más de un elemento (ítem) y un soporte mayor a 2%.

Comente brevemente las conclusiones que obtuvo del análisis.